中国石油大学（华东）
CHINA UNIVERSITY OF PETROLEUM

《大数据分析与挖掘》上机报告

上机 03 基于时间序列分析的股票价格预测

小组成员 1： 张慎岳 2409040129

小组成员 2：姜一 2409040217

组　　号： 29 组

专业班级： 数据 2401 班

完成时间 ：2026 年 11 月 2 日

一、上机任务描述

本次上机的题目为“基于时间序列分析的股票价格预测”。任务要求使用课程案例自带的公开数据集，对个股收盘价序列建立 ARIMA 模型，完成从数据读取与预处理、平稳性检验、差分平稳化、模型识别与定阶、残差诊断到未来预测的完整时间序列建模流程。任务共包含六项具体要求：第一，学习案例中的示例文档和参考代码；第二，使用案例附带的公开数据集完成分析；第三，利用差分运算将非平稳数据变为平稳序列；第四，通过自相关函数和偏自相关函数分析序列特性，选择合适的 ARIMA 模型；第五，通过残差分析，检查残差的平稳性和白噪声特性；第六，利用最佳 ARIMA 模型预测未来一个月的平均收盘价。上述六项要求的落实情况为：第一项对应第二章的代码实现说明，第二至第六项分别对应第三章的 3.1 节、3.4 节、3.5 与 3.6 节、3.7 节、3.9 节。

实验数据方面，本次使用案例附带的聚光科技日线数据（股票代码 300203），数据由通达信提供，随课程案例一同发布，无需额外下载。样本区间为 2021 年 9 月 6 日至 2023 年 6 月 2 日，共 420 个交易日，包含 date、open、high、low、close、volume 六个字段，建模对象为收盘价 close。样本区间内收盘价的取值范围为 16.00 ~ 41.97 元，均值为 27.07 元。

全部实验在 Jupyter Notebook 中完成，使用的软件与主要依赖库版本为：Python 3.13.2、numpy 2.1.3、pandas 2.2.3、statsmodels 0.14.5、matplotlib 3.10.0。

在正式建模之前，需要先对原始数据做三项预处理：

（1）数据文件“聚光科技.xls”并非真正的 Excel 文件，而是 GBK 编码的制表符分隔文本，因此应使用 pd.read_csv(sep="\t", encoding="gbk") 读取，而不能用 pd.read_excel，否则 pandas 无法按 Excel 格式解析该文件。

（2）文件前 3 行分别为股票名称标题、空行和字段名，读取时需要用 skiprows=2 跳过；文件末行为“数据来源:通达信”，需要用正则表达式 ^\d{4}/ 过滤掉，否则该行会被当作数据记录读入，导致 close 字段无法转换为数值型。

（3）构建时间序列时直接使用 420 个真实交易日，不使用 asfreq“B”.ffill() 补齐工作日。补齐会把样本量从 420 扩大到 455，凭空增加约 35 个并不存在的交易日，并使差分序列中的零变化观测由 5 个增至 40 个，这将人为压低序列波动，污染

自相关函数与方差的估计。

基于上述预处理结果，实验按“检验序列性质、差分平稳化、识别相关结构、信息准则定阶、残差诊断、预测与验证”的顺序推进：先由 ADF 检验判断是否需要差分，再由 Ljung-Box 检验判断序列是否含有可建模的信息，随后依据 ACF 与 PACF 确定 p、q 的搜索范围并用 AIC 定阶，最后对残差做三项诊断，并在留出测试集的条件下检验预测效果。第二章给出各环节修改后的主要代码，第三章给出对应的运行结果。

二、修改后的主要代码

2.1 数据读取与时间序列构建

与示例代码相比，这里主要有两处改动：一是针对伪 Excel 文件改用 read_csv 并显式指定 GBK 编码与制表符分隔；二是过滤掉末行的来源说明，按日期排序后直接以收盘价构建序列，不再补齐工作日。

```
df = pd.read_csv(DATA_FILE, sep="\t", encoding="gbk", skiprows=2)
df = df[df["date"].astype(str).str.strip().str.match(r"^\d{4}/")].copy()
df["date"] = pd.to_datetime(df["date"].str.strip())
for c in ["open", "high", "low", "close", "volume"]:
df[c] = pd.to_numeric(df[c])
df = df.sort_values("date").reset_index(drop=True)
ts = df.set_index("date")["close"]       # 420 个真实交易日，不补不填
```

2.2 平稳性检验与差分平稳化

先对原始序列做 ADF 单位根检验，若 p 值大于 0.05 则判为非平稳，再做一阶差分并重新检验；同时对差分序列做 Ljung-Box 白噪声检验，据此确定差分阶数 d。

```
def adf_report(x, name):
    r = adfuller(x.dropna())
    print(f"[{name}] ADF={r[0]:.4f}  p={r[1]:.4f}  临界值 1%={r[4]['1%']:.3f}")
    return r[1]


p_raw = adf_report(ts, "原始收盘价")
ts_diff = ts.diff().dropna()
p_diff = adf_report(ts_diff, "一阶差分")
print(acorr_ljungbox(ts_diff, lags=[6, 12, 24], return_df=True))
d_order = 1 if p_diff < 0.05 else 2
```

2.3 自相关分析与模型定阶

绘制一阶差分序列的 ACF 与 PACF 图用于人工判阶，再对 p、q 在 0~3 范围内做网格搜索，按 AIC 最小准则确定最优阶数，以此替代案例代码中需要额外安装的 pmdarima.auto_arima。

```
fig, axes = plt.subplots(1, 2, figsize=(14, 4))
plot_acf(ts_diff, lags=40, ax=axes[0], title="差分序列 ACF")
plot_pacf(ts_diff, lags=40, ax=axes[1], title="差分序列 PACF", method="ywm")


rows = []
for p in range(4):
    for q in range(4):
        m = ARIMA(ts, order=(p, d_order, q)).fit()
        rows.append({"order": (p, d_order, q), "AIC": m.aic, "BIC": m.bic})
grid = pd.DataFrame(rows).sort_values("AIC").reset_index(drop=True)
best_order = grid.loc[0, "order"]
```

2.4 残差诊断

模型拟合后取残差，依次检验其平稳性（ADF）、白噪声特性（Ljung-Box）与正态性（Jarque-Bera）。

```
model = ARIMA(ts, order=tuple(best_order)).fit()
resid = model.resid[1:]
adf_report(resid, "残差")
print(acorr_ljungbox(resid, lags=[6, 12, 24], return_df=True))
jb = jarque_bera(resid)
```

2.5 预测未来一个月的平均收盘价

以全样本拟合的模型向前预测 21 个交易日（A 股一个月约 21 个交易日），输出逐日预测值与 95% 置信区间，并以这 21 个预测值的平均数作为未来一个月的平均收盘价。

```
fc_obj = model.get_forecast(steps=21)
fc, ci = fc_obj.predicted_mean, fc_obj.conf_int(alpha=0.05)
print(f"未来一个月平均收盘价 = {fc.mean():.4f} 元")
```

以上五节代码按建模流程依次执行，其运行结果与对应的图表见第三章。

三、实验结果

3.1 探索性分析

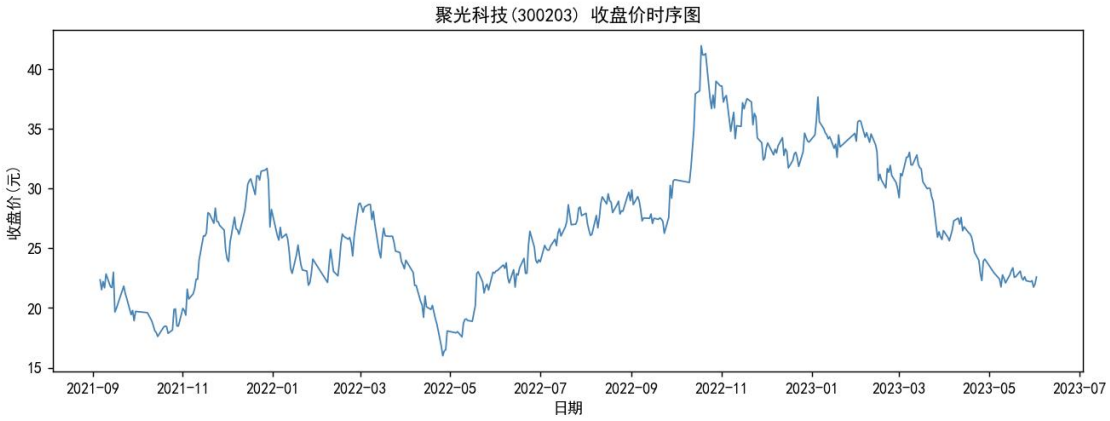


图 1　聚光科技收盘价时序图

图 1 显示，收盘价在样本区间内经历了明显的上升与回落过程，价格水平随时间大幅漂移，并不存在围绕某一固定均值上下波动的特征，据此初步判断该序列非平稳。

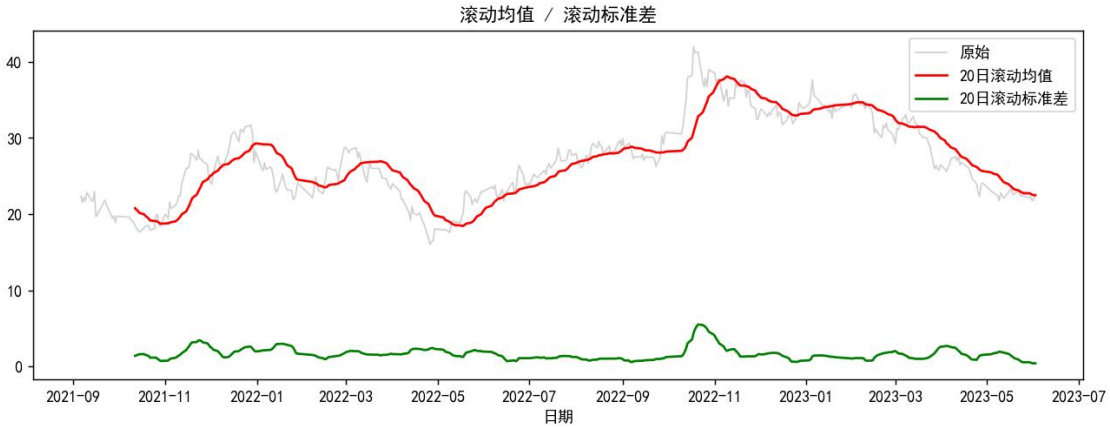


图 2　收盘价的 20 日滚动均值与滚动标准差

图 2 中 20 日滚动均值随时间显著变化，先从 20 元附近上升至 40 元附近，随后又回落至 22 元附近；相比之下滚动标准差的变化幅度较小。均值随时间显著漂移而方差相对稳定，进一步支持“序列非平稳”的判断，需通过定量检验加以确认。

3.2 平稳性检验

对原始收盘价序列做 ADF 单位根检验（原假设为序列存在单位根，即非平稳），结

果如表 1 所示。

表 1　原始收盘价序列 ADF 检验结果

ADF 统计量	p 值	1% 临界值	5% 临界值	10% 临界值	结论
-1.9090	0.3279	-3.446	-2.868	-2.570	非平稳

ADF 统计量为 -1.9090，p 值为 0.3279，大于 0.05 的显著性水平，且统计量的绝对值小于各显著性水平下临界值的绝对值，因此不能拒绝“存在单位根”的原假设，即原始收盘价序列为非平稳序列，需要对其进行差分处理。

3.3 纯随机性检验

在进行差分处理之前，先对原始序列做 Ljung-Box 纯随机性检验，判断序列是否值得建模，结果如表 2 所示。

表 2　原始序列 Ljung-Box 白噪声检验结果

延迟阶数	LB 统计量	p 值	结论
6	2248.1174	0.0000	拒绝原假设，非白噪声
12	4016.6101	0.0000	拒绝原假设，非白噪声
24	6318.2357	0.0000	拒绝原假设，非白噪声

在 6、12、24 阶延迟下，检验的 p 值均为 0.0000，远小于 0.05，因此拒绝“序列为纯随机序列”的原假设，说明该序列不是白噪声，其中含有可提取的信息，具备建模价值。

严格意义上纯随机性检验应在平稳序列上进行；此处按教材给出的流程先对原始序列做检验，用以判断该序列是否含有值得建模的信息。

3.4 差分平稳化

对收盘价序列做一阶差分（等价于日收益），并对差分后的序列重新做平稳性与白噪声检验，结果如表 3 所示。

表 3　一阶差分序列的 ADF 与 Ljung-Box 检验结果

检验项	统计量	p 值	结论
ADF（一阶差分）	-21.6801	0.0000	平稳
Ljung-Box（延迟 6 阶）	4.0636	0.6681	白噪声
Ljung-Box（延迟 12 阶）	10.5689	0.5662	白噪声
Ljung-Box（延迟 24 阶）	19.3318	0.7341	白噪声

差分后序列的 ADF 统计量为 -21.6801，p 值为 0.0000，远小于 0.05，且统计量远低于 1% 水平下的临界值 -3.446，说明一阶差分后序列已经平稳。同时，差分序列在 6、12、24 阶延迟下的 Ljung-Box 检验 p 值分别为 0.6681、0.5662、0.7341，均大于 0.05，说明差分序列已是白噪声，日收益中不存在可利用的线性自相关结构。

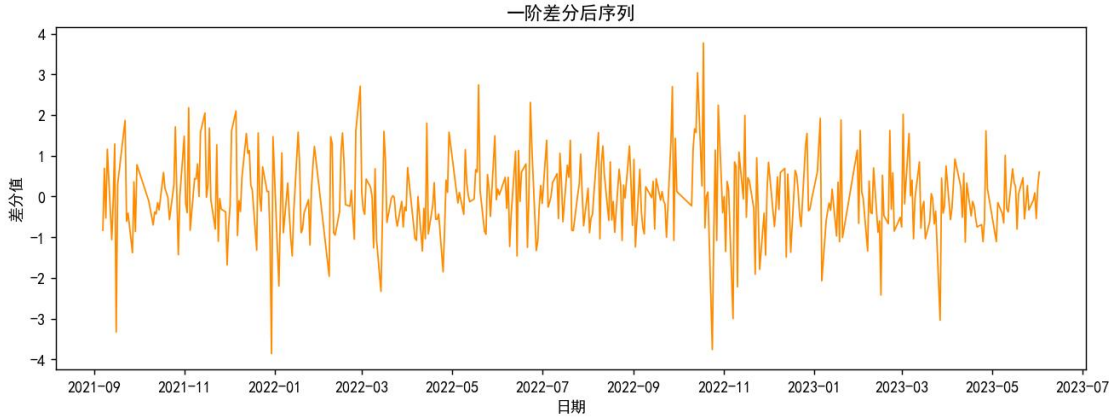


图 3　一阶差分后的序列

如图 3 所示，一阶差分后的序列围绕 0 上下波动，无明显趋势与周期性，符合平稳序列的直观特征，与上述检验结论一致。据此确定差分阶数 d = 1；由于一阶差分已使序列充分平稳，不再做二阶差分，以避免过差分放大残差、降低预测精度。

3.5 自相关与偏自相关分析

图 4 给出一阶差分序列的自相关函数（ACF）与偏自相关函数（PACF）图。

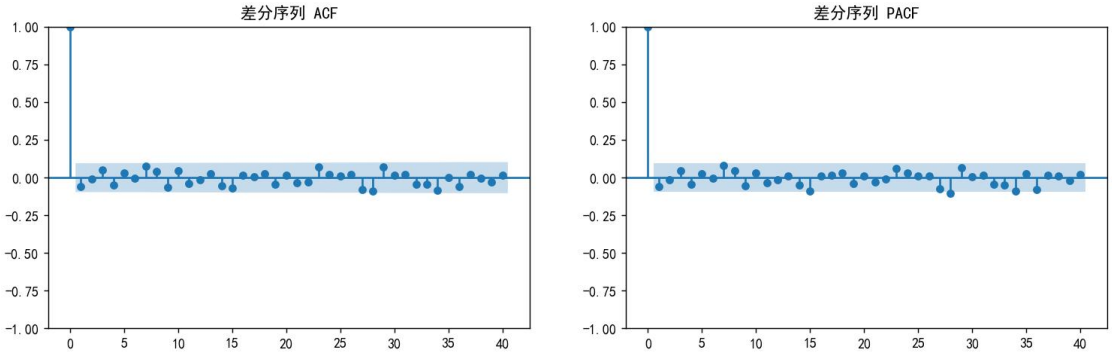


图 4　一阶差分序列的 ACF 与 PACF 图

由图 4 可见，除个别延迟阶数外，绝大多数自相关系数与偏自相关系数都落在 95% 置信区间（图中蓝色阴影区域）内，说明差分序列的自相关性很弱，这与 3.4 节中 Ljung-Box 检验判定其为白噪声的结论相互印证。据此可以判断 p、q 的取值应当较小，可在 0~3 的范围内进一步由信息准则确定。

3.6 模型定阶与拟合

对 p、q 均在 0~3 取值、d = 1 的 16 个候选 ARIMA 模型逐一拟合并计算 AIC 与 BIC，按 AIC 从小到大排列，前 5 名如表 4 所示。

表 4　AIC / BIC 网格搜索结果（前 5 名）

模型阶数 (p, d, q)	AIC	BIC
(0, 1, 0)	1190.78	1194.82
(0, 1, 1)	1191.21	1199.29
(1, 1, 0)	1191.24	1199.32
(3, 1, 2)	1191.90	1216.13
(2, 1, 3)	1191.91	1216.14

AIC 最小的模型为 ARIMA(0,1,0)，其 AIC = 1190.78、BIC = 1194.82；排名第二的 ARIMA(0,1,1) 的 AIC 为 1191.21，与最优模型仅相差 0.43，两者几乎并列。据此选择 ARIMA(0,1,0) 作为最终模型。该模型不含自回归项与移动平均项，仅做一次差分，即随机游走模型。

p、q 的搜索范围取 0~3，主要基于两点考虑：一是图 4 中各阶相关系数基本落在置信区间内，最优阶数不会太高；二是样本仅 420 个观测，p、q 取值过大会引入较多

待估参数，容易造成过拟合。此外，表 4 中 BIC 的排列顺序与 AIC 一致，说明最优阶数的选择并不依赖单一准则。

3.7 残差分析

对 ARIMA(0,1,0) 模型的残差做三项诊断检验，结果如表 5 所示。

表 5　残差诊断检验结果

检验项	统计量	p 值	结论
残差平稳性（ADF）	-21.6801	0.0000	平稳，通过
残差白噪声（LB，6 阶）	4.0636	0.6681	白噪声，通过
残差白噪声（LB，12 阶）	10.5689	0.5662	白噪声，通过
残差白噪声（LB，24 阶）	19.3318	0.7341	白噪声，通过
残差正态性（Jarque-Bera）	37.6775	0.0000	不服从正态

残差平稳性方面，残差序列的 ADF 统计量为 -21.6801，p 值为 0.0000，说明残差序列平稳。

残差的白噪声特性方面，6、12、24 阶延迟下的 Ljung-Box 检验 p 值分别为 0.6681、0.5662、0.7341，均大于 0.05，说明残差已是白噪声，即模型已充分提取序列中的线性相关信息，模型设定是合适的。

残差正态性方面，Jarque-Bera 统计量为 37.6775，p 值为 0.0000，偏度为 0.0066，峰度为 4.4690，残差不服从正态分布。峰度大于 3 表明残差呈现尖峰厚尾特征，这是金融时间序列的典型现象，并不影响上述检验结论，只是基于正态假设给出的置信区间会偏保守。

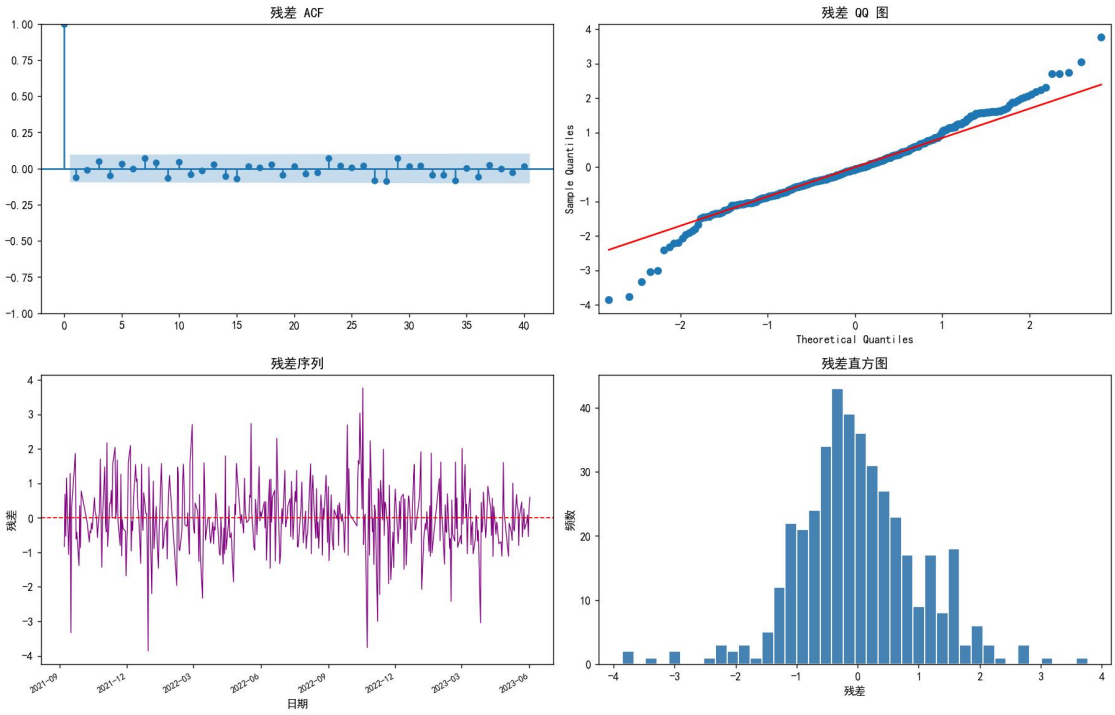


图 5　残差诊断四联图（ACF、QQ 图、残差序列、直方图）

图 5 的残差诊断四联图与上述结论一致：残差 ACF 各阶基本落在置信区间内；QQ 图两端明显偏离直线，印证了厚尾特征；残差序列围绕 0 波动且无趋势；直方图呈现明显的尖峰形态。

3.8 样本外验证

为检验模型的实际预测能力，将最后 21 个交易日（2023 年 5 月 5 日 ~ 2023 年 6 月 2 日）留作测试集，用前 399 个交易日的数据训练同阶数的 ARIMA 模型并进行预测，结果如图 6 和表 6 所示。



图 6　样本外验证：测试集实际值与预测值对比

表 6　样本外验证误差指标

RMSE	MAE	MAPE	实际均值（元）	预测均值（元）
0.6354	0.5443	2.44%	22.5048	22.9900

预测值与实际值之间的 RMSE 为 0.6354，MAE 为 0.5443，MAPE 为 2.44%。测试集的实际均值为 22.5048 元，预测均值为 22.9900 元，二者相差约 0.49 元。就一个月期的预测而言，上述误差处于较小水平；但图 6 中预测值很快收敛为一条接近水平的直线，只能反映价格的平均水平，无法刻画逐日的价格波动。

3.9 未来一个月平均收盘价预测

样本外验证之后，改用全部 420 个交易日重新拟合 ARIMA(0,1,0) 模型，再向前预测 21 个交易日（2023 年 6 月 5 日 ~ 2023 年 7 月 3 日）。之所以这样做，是因为最终预测应以截至最新一天的全部信息为条件，若仍使用前 399 个交易日训练，会白白丢掉最近 21 个交易日的观测。逐日预测值及其 95% 置信区间如表 7 所示（节选）。

表 7　未来 21 个交易日收盘价预测结果（节选）

预测日期	预测收盘价（元）	95% 置信下限（元）	95% 置信上限（元）
2023-06-05	22.60	20.641	24.559
2023-06-06	22.60	19.829	25.371
2023-06-07	22.60	19.206	25.994
2023-06-08	22.60	18.681	26.519
2023-06-09	22.60	18.219	26.981
2023-07-03	22.60	13.621	31.579
平均	22.60	16.419	28.781



图 7　未来 21 个交易日收盘价预测结果与 95% 置信区间

预测结果显示，未来 21 个交易日的收盘价预测值均为 22.60 元，因此未来一个月的平均收盘价预测值即为 22.60 元。这一结果源于 ARIMA(0,1,0) 的随机游走性质。模型中既无自回归项也无移动平均项时，向前任意步长的最优预测恒等于最后一个观测值，即 2023 年 6 月 2 日的收盘价 22.60 元。

由表 7 可见，95% 置信区间随预测步长迅速变宽：第 1 个交易日为 20.641 ~ 24.559 元（宽度约 3.9 元），到第 21 个交易日已扩大为 13.621 ~ 31.579 元（宽度约 18.0 元）。这说明预测的不确定性随步长快速累积，该模型仅具备极短期的参考价值。作为对照，历史最后 21 个交易日的实际平均收盘价为 22.5048 元，与预测值 22.60 元较为接近。

至此，从数据读取到未来预测的建模流程已全部完成，各项结果如上所述。下面从主要结论、模型评价与改进方向三个方面对本次实验加以总结。

四、对实验结果的评价

4.1 主要结论

聚光科技收盘价序列为非平稳序列（ADF 统计量 -1.9090，p = 0.3279），一阶差分后转为平稳序列（ADF 统计量 -21.6801，p = 0.0000），由此确定差分阶数 d = 1。

进一步做纯随机性检验，一阶差分序列经 Ljung-Box 检验判定为白噪声（各阶 p 值均大于 0.05）；ACF/PACF 图中各阶相关系数也基本落在置信区间内，说明日收益序

列中不含可利用的线性自相关结构。

在 AIC 准则下，最优模型为 ARIMA(0,1,0)，即随机游走模型；它与含 AR/MA 项的模型（如 ARIMA(0,1,1)，AIC = 1191.21）的差距不足 0.5，进一步印证该序列的可预测性很弱。

残差的诊断检验通过：残差序列平稳且为白噪声，说明模型设定合理；但残差呈尖峰厚尾（峰度 4.4690），不服从正态分布。

在上述模型下，对未来一个月（21 个交易日）平均收盘价的预测值为 22.60 元，样本外验证的 MAPE 为 2.44%。

4.2 模型评价

从预测精度看，ARIMA(0,1,0) 在一个月的短期预测中误差较小（MAPE 仅 2.44%）。但这一精度主要来自随机游走模型“预测值等于当前价格”的特性：股价短期波动幅度有限，即使以当前值直接外推，误差也不会太大，因此该指标并不能说明模型具有真正的预测能力。

从方法论角度看，实验完整执行了时间序列建模的标准流程：依次完成平稳性检验、差分平稳化、ACF/PACF 分析、信息准则定阶与残差三重检验，且各项诊断检验均通过。同时，这一结果也表明：单纯依赖历史收盘价的线性模型无法预测股价的未来走势，这与弱有效市场假说的预期一致。若历史价格中真的存在可利用的规律，市场参与者会迅速利用并使其消失。

4.3 不足与改进方向

模型的不足主要有三点：一是最优模型退化为随机游走，预测值恒为常数，无法刻画趋势与拐点；二是置信区间随预测步长迅速变宽，中长期预测基本失去意义；三是仅使用收盘价这一单变量，未纳入成交量、市场情绪、政策等外生因素，也未处理金融序列中普遍存在的条件异方差。

后续可从以下方向改进：改用对数收益率建模并与原序列做 AIC 对比；引入外生变量建立 ARIMAX 模型；对波动率单独建立 GARCH 模型以刻画条件异方差；或尝试 LSTM 等能够捕捉非线性结构的模型。